

振り返りと導入

前回までは指数型分布族について調べていた。本稿では次のことを行う:

- 統計モデルを定義する。
- 最尤推定量を定義する。
- Kullback-Leibler ダイバージェンスを定義する。

本稿では指数型分布族は open であるとする。

1 統計モデル

定義 1.1 (統計モデル). X を可測空間とする。多様体 $\Theta \neq \emptyset$ と写像 $\mathbf{p}: \Theta \rightarrow \mathcal{P}(X)$ の組 (Θ, \mathbf{p}) が X 上の統計モデル (statistical model) であるとは、ある実現 (p, μ) が存在して次をみたすことをいう:

- (i) $p: \Theta \times X \rightarrow \mathbb{R}_{>0}, (\theta, x) \mapsto p_\theta(x)$
 - (i-a) $\forall \theta \in \Theta, p_\theta$ は可測関数
 - (i-b) μ -a.e. $x \in X, p(\cdot, x)$ は C^∞ 関数
- (ii) μ は σ -有限な測度である。
- (iii) $\mathbf{p}(\theta) = p_\theta \cdot \mu$

命題 1.2. 指数型分布族 \mathcal{P} とその最小次元実現 (V, T, μ) をひとつ固定したとき、 (Θ, P) は X 上の統計モデルである。ただし Θ は自然パラメータ空間、 P は自然パラメータ座標の逆写像である。

証明 $p_\theta(x) = \exp[\langle \theta, T(x) \rangle - \psi(\theta)]$ とおけばよい。 □

例 1.3 (統計モデルの例).

- Cauchy 分布族

命題-定義 1.4 (スコア関数). 実現 (p, μ) に対し関数 $l: \Theta \times X \rightarrow \mathbb{R}, (\theta, x) \mapsto l_x(\theta) := \log p_\theta(x)$ と定め、実現 (p', μ') に対し同様に l' を定めると、 $dl_x = dl'_x$ (a.e. x) が成り立つ。そこで $dl: \Theta \times X \rightarrow T^\vee \Theta$ を統計モデル (Θ, \mathbf{p}) のスコア (score) という。

証明 $(p, \mu), (p', \mu')$ を考えると、

$$\frac{p'_\theta(x)}{p_\theta(x)} = \frac{d\mu}{d\mu'}(x) \quad (\text{a.e. } x) \quad (1.1)$$

\log をとって θ で微分すれば $dl'_\theta = dl_\theta$ (a.e. x) を得る。 □

命題 1.5. 指数型分布族において

$$E_{\mathbf{p}(\theta)}[(dl_\theta)^2] = g_\theta \quad (1.2)$$

が成り立つ。

証明 $dl_\theta = d(\langle \theta, T \rangle - \psi(\theta)) = T(x) - d\psi_\theta$ だから、 $E[T] = d\psi_\theta$ に注意すれば

$$E[(dl_x)_\theta^2] = E[(T - E[T])^2] = \text{Var}[T] = g_\theta \quad (1.3)$$

である。 \square

定義 1.6 (Fisher 計量). $E_{\mathbf{p}(\theta)}[(dl_x)_\theta^2]$ を統計モデル (Θ, \mathbf{p}) の **Fisher 計量 (Fisher metric)** という。

2 最尤推定

定義 2.1 (i.i.d. 拡張). \mathcal{X} 上の統計モデル (Θ, \mathbf{p}) に対し、 \mathcal{X}^k 上の統計モデル (Θ, \mathbf{p}^k) を (Θ, \mathbf{p}) の **i.i.d. 拡張 (i.i.d. extension)** という。ただし $\mathbf{p}^k(\theta) := \mathbf{p}(\theta) \times \cdots \times \mathbf{p}(\theta)$ (積測度) である。

命題 2.2. 指数型分布族の i.i.d. 拡張は指数型分布族である。

証明 元の指数型分布族の実現 (V, T, μ) に対し、 (V, T', μ^k) , $T'(x) := \sum_{i=1}^k T(x_i)$ が i.i.d. 拡張の実現となる。 \square

命題-定義 2.3 (最尤推定量). 可測写像 $\hat{\theta}: \mathcal{X} \rightarrow \Theta$ に関する条件を考える。実現 (p, μ) に対し a.e. $x \in \mathcal{X}$, $\hat{\theta}(x) \in \text{argmax}_{\theta \in \Theta} p_\theta(x)$ が成り立つとき、 $\hat{\theta}$ を (p, μ) に関する**最尤推定量**と呼ぶことにする。このとき次は同値である:

- (1) $\hat{\theta}$ はある実現 (p, μ) に関する最尤推定量である。
- (2) $\hat{\theta}$ は任意の実現 (p, μ) に関する最尤推定量である。

そこで、上の条件のいずれかが成り立つとき、 $\hat{\theta}$ を統計モデル (Θ, \mathbf{p}) の**最尤推定量 (maximum likelihood estimator)**と呼ぶ。

証明 (2) \Rightarrow (1) は明らか。(1) \Rightarrow (2) は argmax の定義および $q_\theta = p_\theta \frac{d\mu}{d\nu}$ に注意すればわかる。 \square

命題 2.4 (尤度方程式). (1) $\hat{\theta}$ が最尤推定量ならば、(2) a.e. x に対し $\hat{\theta}(x)$ は**尤度方程式 (likelihood equation)** $(dl_x)_\theta = 0$ の解である。さらに指数型分布族においては逆も成り立つ。

証明 (1) \Rightarrow (2) は l_x が θ に関し微分可能であることから従う。指数型分布族の場合、(2) \Rightarrow (1) は $l_x(\theta) = \langle \theta, T(x) \rangle - \psi(\theta)$ が上に凸であることから従う。 \square

例 2.5 (最尤推定量の例).

- 正規分布族の場合

- Cauchy 分布族の場合

3 Kullback-Leibler ダイバージェンス

定義 3.1 (Kullback-Leibler ダイバージェンス). 関数 $D: \mathcal{P}(X) \times \mathcal{P}(X) \rightarrow [0, \infty]$,

$$D(\mu \| \nu) := \begin{cases} E_{\mu} \left[\log \frac{d\mu}{d\nu} \right] & (\mu \sim \nu) \\ \infty & (\mu \not\sim \nu) \end{cases} \quad (3.1)$$

を **Kullback-Leibler ダイバージェンス** と呼ぶ。

例 3.2 (KL ダイバージェンスの例).

- 有限集合上の確率分布の族の場合
- 正規分布族の場合

$X = \{1, \dots, n\}, n \in \mathbb{N}$ の場合に最尤推定量と KL ダイバージェンスの関係を考える。

定義 3.3 (経験分布). $x = (x_1, \dots, x_k) \in X^k$ に対し

$$\hat{p}_x := \frac{1}{k} \sum_{i=1}^k \delta^{x_i} \quad (3.2)$$

を x により定まる**経験分布 (empirical distribution)** という。

命題 3.4 (最尤推定量と KL ダイバージェンス). (Θ, \mathbf{p}) を X 上の統計モデルとし、 k 個の i.i.d. 拡張 (Θ, \mathbf{p}^k) を考える。 $x = (x_1, \dots, x_k) \in X^k$ とし、 \hat{p}_x を x により定まる経験分布とする。このとき、 $\mathbf{p}(\Theta)$ が \hat{p}_x と同値な確率測度を含むならば次が成り立つ:

$$\operatorname{argmin}_{\theta \in \Theta} D(\hat{p}_x \| \mathbf{p}^k(\theta)) \subset \operatorname{argmax}_{\theta \in \Theta} p_{\theta}^k(x) \quad (3.3)$$

証明 argmin を考えるから $\hat{p}_x \sim \mathbf{p}^k(\theta)$ なる θ を考えればよい。

$$D(\hat{p}_x \| \mathbf{p}^k(\theta)) = E_{\hat{p}_x} \left[\log \frac{d\hat{p}_x}{d(\mathbf{p}^k(\theta))} \right] \quad (3.4)$$

$$= E_{\hat{p}_x} \left[\log \frac{d\hat{p}_x}{di} \right] - E_{\hat{p}_x} \left[\log \frac{d(\mathbf{p}^k(\theta))}{di} \right] \quad (3.5)$$

$$= (\theta \text{ によらない項}) - \frac{1}{k} \log p_{\theta}^k(x) \quad (3.6)$$

□

今後の予定

- 射影

参考文献

- [AJLS17] Nihat Ay, Jürgen Jost, Hông Vân Lê, and Lorenz Schwachhöfer, **Information Geometry**, Ergebnisse der Mathematik und ihrer Grenzgebiete 34, vol. 64, Springer International Publishing, Cham, 2017.
- [Ama16] Shun-ichi Amari, **Information Geometry and Its Applications**, Applied Mathematical Sciences, vol. 194, Springer Japan, Tokyo, 2016 (en).
- [AN07] Shun-ichi Amari and Hiroshi Nagaoka, **Methods of Information Geometry**, Translations of Mathematical Monographs, vol. 191, American Mathematical Society, Providence, Rhode Island, April 2007 (en).